

3.2 ел

а) Как было показано на лекции,

$$\hat{\theta} = (X^T X + \lambda I_d)^{-1} X^T y$$

$$\text{Тогда } \text{MSE}_{\hat{\theta}}(\theta) = \mathbb{E}[(\hat{\theta} - \theta)^T (\hat{\theta} - \theta)] =$$

$$= \mathbb{E}[\hat{\theta}^T \hat{\theta} - 2 \hat{\theta}^T \theta + \theta^T \theta] =$$

$$= \mathbb{E}[\underbrace{y^T X (X^T X + \lambda I_d)^{-1} (X^T X + \lambda I_d)^{-1} X^T y}_{W_{\lambda}} -$$

$$- 2 ((X^T X + \lambda I_d)^{-1} X^T y)^T \theta + \theta^T \theta] =$$

$$= \mathbb{E}[y^T X W_{\lambda}^2 X^T y - 2 \theta^T W_{\lambda} X^T y + \theta^T \theta]$$

$$= \mathbb{E}[\text{tr}(X W_{\lambda}^2 X^T y y^T) - 2 \theta^T W_{\lambda} X^T y + \theta^T \theta] =$$

$$= \text{tr}(X W_{\lambda}^2 X^T \mathbb{E}[y y^T]) - 2 \theta^T W_{\lambda} X^T \mathbb{E}[y] + \theta^T \theta$$

$$= \left\{ \begin{array}{l} \text{в предположении, что модель гауссовская} \end{array} \right.$$

$$= \text{tr}(X W_{\lambda}^2 X^T \sigma^2) - 2 \theta^T W_{\lambda} X^T X \theta + \theta^T \theta$$

$$= \text{tr}(X W_{\lambda}^2 X^T (\text{Cov } y + (\mathbb{E} y)(\mathbb{E} y)^T)) - 2 \theta^T W_{\lambda} X^T X \theta + \theta^T \theta = \text{tr}(X W_{\lambda}^2 X^T \cdot \sigma^2 + (X \theta)^T \cdot X \theta) - 2 \theta^T W_{\lambda} X^T X \theta + \theta^T \theta$$

$$\Leftrightarrow \left\{ \begin{array}{l} \text{а также т.к. } \text{Cov } y = \mathbb{E}[(y - \mathbb{E} y)(y - \mathbb{E} y)^T] =$$

$$= \mathbb{E}[y y^T - 2 y (\mathbb{E} y)^T + \mathbb{E} y (\mathbb{E} y)^T] \Leftrightarrow$$

$$\Leftrightarrow \text{tr}(X W_{\lambda}^2 X^T (\text{Cov } y + 2 \mathbb{E} y (\mathbb{E} y)^T - \mathbb{E} y (\mathbb{E} y)^T)) -$$

$$- 2 \theta^T W_{\lambda} X^T \mathbb{E} y + \theta^T \theta = \text{tr}(X W_{\lambda}^2 X^T (\sigma^2 I_n +$$

$$+ X\theta \cdot (X\theta)^T)) - 2\theta^T W_2 X^T \cdot X\theta + \theta^T \theta$$

Проблема: при $\lambda = 0$ получим $W_2 = (X^T X)^{-1}$

$$\Rightarrow MSE_{\theta}(\theta) = \text{tr}(X(X^T X)^{-1} X^T \cdot (\sigma^2 I_n + X\theta(X\theta)^T))$$

$$- 2\theta^T \theta + \theta^T \theta = \text{tr}(X(X^T X)^{-1} X^T \sigma^2 + X(X^T X)^{-1} X^T X\theta \cdot$$

$$\cdot \theta^T X^T) = \theta^T \theta = \text{tr}(X(X^T X)^{-1} \sigma^2 + \cancel{X\theta \cdot \theta^T X^T})$$

$$- \theta^T \theta$$

$$b) \langle \hat{y}, e \rangle = \langle \hat{y}, y - \hat{y} \rangle = (X \cdot \underbrace{(X^T X + \lambda I_d)^{-1} X^T y}_{W_2})^T \cdot y -$$

$$- (X(X^T X + \lambda I_d)^{-1} X^T y)^T \cdot (-//-) =$$

$$= y^T X W_2 X^T y - y^T X W_2 X^T \cdot (X W_2 X^T y) =$$

$$= \underbrace{y^T X W_2}_{\neq 0} \underbrace{(I_d - X^T X W_2)}_{\neq 0} \underbrace{X^T y}_{\neq 0} \neq 0, \text{ z.B. g.}$$

3.2 a) 2

⊖ Найти оптимальное решение:

⊖ $P_{\lambda x^2}(p) = \argmin_x \underbrace{\left(\frac{1}{2}(x-p)^2 + \lambda x^2 \right)}_{g(x,p)}$

$$\partial g(x,p) = x - p + 2\lambda x$$

т.к. $x_0 = P_{\lambda x^2}(p) \Rightarrow \cancel{0 \in p - x_0} \quad 0 \in \partial g(x_0, p)$

или: $0 \in \partial g(x_0, p) \Leftrightarrow 0 = x_0 - p + 2\lambda x_0 \Leftrightarrow$

$$\Leftrightarrow x_0 = \frac{p}{1+2\lambda} \quad \text{— всегда } \exists \text{—т, т.к. } \lambda \geq 0.$$

$$\Rightarrow P_{\lambda x^2}(p) = \frac{p}{1+2\lambda}.$$

По уб-ю 5 с леммы, если θ - реш-е

~~то~~ $F(\theta) + 2R(\theta) \rightarrow \min_{\theta}$, то $\theta = P_{\lambda R}(\theta - \nabla F(\theta))$

В предположении, что есть ск-ть ~~те~~

итер. метода, имеем:

$$\theta_{k+1} = \frac{\theta_k - \nabla F(\theta_k)}{1+2\lambda} = \frac{\theta_k - \nabla \|y - X\bar{\theta}_k\|_2^2}{1+2\lambda}, \text{ где } \bar{\theta}_k = \begin{pmatrix} 0 \\ \theta_k \\ 0 \end{pmatrix} \leftarrow k\text{-я позиция}$$

$$\theta_{k+1} = \frac{\theta_k + 2y^T[X]_{k-} - 2\theta_k}{1+2\lambda} = \frac{2y^T[X]_{k-} - \theta_k}{1+2\lambda}$$

Многочл. случай: $P_{\lambda \|x\|_2^2}(p) = \arg\min_x \left(\frac{1}{2} \|x-p\|_2^2 + \lambda \|x\|_2^2 \right) = \arg\min_x \left(\frac{1}{2} \sum_{i=1}^d (x_i - p_i)^2 + \lambda \sum_{i=1}^d x_i^2 \right) = (\dots, P_{\lambda x_i^2}(p_i), \dots)^T$

"Св-ва" λ : 1) влияние от лассо-регрессии
в том, что ~~есть~~ итерации "плавные", т.к.
нет резкого ^{резкого} закручивания θ_k ; а ещё ск-ть более быстрая

2) Ск-ть геометрическая, т.к. в знаменателе
каждый раз $(1+2\lambda)$ сойт \Rightarrow при $\lambda \rightarrow \infty$
очень быстро $\theta_k \rightarrow 0$, а при $\lambda=0$ получается
градиентный спуск для $F(\theta)$.